

Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук
Основная образовательная программа
Прикладная математика и информатика

КУРСОВАЯ РАБОТА
ИССЛЕДОВАТЕЛЬСКИЙ ПРОЕКТ НА ТЕМУ
«АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ
YANDEX DATALENS, НА ПРИМЕРЕ ДАННЫХ IPINYOU»

Выполнил студент группы БПМИ 242, 2 курса,
Наседкин Дмитрий Сергеевич

Руководитель:
Доцент, Базовая кафедра Т-Банка
Иванов Андрей Александрович

Аннотация

Real-Time Bidding (RTB) – одно из наиболее значимых и динамично развивающихся направлений последних лет в области вычислительной рекламы (programmatic advertising). Этот механизм повышает прозрачность и эффективность экосистемы медийной рекламы и способствует устойчивому её развитию. RTB позволяет рекламодателям показывать нужное объявление нужному пользователю, издателям – эффективнее монетизировать контент, используя аудиторию своих сайтов, а пользователям – получать более релевантную рекламу благодаря персонализации. В такой модели особую роль играют анализ данных и разработка стратегии ставок. При этом исследования в области вычислительных методов в рекламе долгое время ограничивались дефицитом публичных датасетов, необходимых для анализа, сопоставления алгоритмов и воспроизводимости результатов.

В работе используется открытый датасет **iPinYou** – ведущей китайской компании в сфере рекламных технологий, опубликованный в рамках международного соревнования по RTB-алгоритмам в 2013 году [5]. Датасет включает логи рекламных аукционов, ставок, показов, кликов и последующих конверсий, отражая как рыночную среду, так и полный путь пользователя с точки зрения рекламодателя. Эти данные позволяют исследовать важные прикладные задачи, связанные с оценкой эффективности рекламы и оптимизацией закупки.

В рамках работы будет выполнен подробный анализ данных и рассмотрены подходы к оценке эффективности рекламной кампании в RTB. Для подготовки и удобного анализа данные будут загружены и структурированы в базе данных ClickHouse. Далее с использованием Yandex DataLens будет проведён статистический и визуальный анализ: расчёт ключевых показателей эффективности и построение воронки RTB-аукциона. Дополнительно будет выполнена оценка влияния различных факторов (параметров

аукциона, характеристик пользователя/площадки/времени и др.) на итоговую эффективность рекламных кампаний.

Ключевые слова: Real-Time Bidding (RTB), iPinYou Dataset, Yandex DataLens, Cost Per Mille (CPM), Click-Through Rate (CTR), Conversation Rate (CVR), Effective Cost Per Click (eCPC), Effective Cost Per Action (eCPA), RTB-воронка, ClickHouse.

Содержание

1	Основные термины и определения	4
2	Введение	7
2.1	Цель	11
2.2	Объект исследования	11
2.3	Предмет исследования	11
2.4	Методы исследования	12
2.5	Задачи	12
2.6	Актуальность работы	13
2.7	План работы	14
3	Описательный анализ данных	16
3.1	Журнал ставок	16
3.2	Журнал показов / кликов / конверсий	18
3.3	Категории рекламодателей	20
3.4	Профиль пользователя	20
3.5	Таблица регионов и городов	20
3.6	Предварительная обработка данных	21
4	Обзор источников	22
5	Проектирование и разработка макета интерактивного даш- борда	24
5.1	Концепция и архитектура дашборда	24
5.2	Эффективность RTB-рекламы	25
5.3	Разведочный анализ данных (EDA)	27
5.4	Многофакторный анализ KPI рекламных кампаний	28
6	Инфраструктура хранения и подготовки данных	31

6.1	Выбор и развёртывание СУБД	31
6.2	Схема исходных таблиц	33
6.3	Формирование аналитической таблицы <code>ads_data</code>	34
6.4	Подключение ClickHouse к DataLens	35
6.5	Формирование датасета	36
7	Заключение	38
7.1	Описание выполненных задач	38
7.2	Описание интерактивной визуализации	39
7.3	Ответ на основной вопрос работы	45
7.4	Ограничения работы	47
7.5	Развитие работы	47
8	Описание применения генеративной модели	49
	Приложение	54

1 Основные термины и определения

- 1 **iPinYou** – международная дочерняя компания китайской MarTech-компании DeepZero, основанная в 2009 году и специализирующаяся на поддержке брендов в принятии маркетинговых решений на рынке Китая [1].
- 2 **Yandex DataLens** – облачная платформа бизнес-аналитики и визуализации данных, предназначенная для сбора, интеграции, аналитической обработки и представления данных в виде интерактивных отчётов, панелей мониторинга (дашбордов) и аналитических виджетов [2].
- 3 **ClickHouse** – высокопроизводительная распределённая система управления базами данных колоночного типа, предназначенная преимущественно для аналитической обработки данных в условиях больших объёмов и высокой скорости поступления информации [3].
- 4 **Real-Time Bidding (RTB)** – это технология интернет-рекламы, при которой показ рекламного объявления распределяется на основе автоматизированного аукциона, проводимого в режиме реального времени.
- 5 **Demand-Side Platform (DSP)** – онлайн-платформа для рекламодателей, которая автоматически покупает показы рекламы на разных площадках через аукционы (в т.ч. RTB), настраивая таргетинг, ставки и оптимизацию рекламных кампаний [10].
- 6 **Cost Per Mille (CPM)** – модель ценообразования в рекламе, при которой стоимость рассчитывается за 1000 показов объявления; так-

же используется как метрика:

$$\text{CPM} = \frac{\text{Cost}}{\text{Impressions}} \cdot 1000$$

.

7 Click-Through Rate (CTR) – показатель кликабельности, равный доле кликов от числа показов:

$$\text{CTR} = \frac{\text{Clicks}}{\text{Impressions}}$$

.

8 Conversion Rate (CVR) – коэффициент конверсии, равный доле целевых действий от числа кликов (реже — от числа показов):

$$\text{CVR} = \frac{\text{Conversions}}{\text{Clicks}}$$

.

9 Effective Cost Per Click (eCPC) – эффективная стоимость клика, рассчитываемая как общие затраты, делённые на число кликов:

$$\text{eCPC} = \frac{\text{Cost}}{\text{Clicks}}$$

.

10 Effective Cost Per Action (eCPA) — эффективная стоимость конверсии (действия), рассчитываемая как общие затраты, делённые на число конверсий:

$$\text{eCPA} = \frac{\text{Cost}}{\text{Conversions}}.$$

11 RTB-воронка – последовательность этапов прохождения рекламно-

го показа в RTB и соответствующих потерь объёма, обычно включающая: ставки → выигрыши аукциона/показы → клики → конверсии.

12 **Спарклайн (Sparkline)** – небольшой линейный график без осей и координат, который встраивается в текст, таблицу или карточку индикатора для компактного отображения тренда или вариации данных.

13 **Относительный спред (Relative Spread)** – в контексте RTB-аукционов это разница между ставкой (bidding price) и фактической ценой показа (paying price), нормированная на величину ставки:

$$\text{Relative Spread} = \frac{\text{Bidding Price} - \text{Paying Price}}{\text{Bidding Price}}$$

. Показывает, какую долю от максимальной ставки удалось сэкономить благодаря механизму аукциона второй цены.

2 Введение

Появившись в 2009 году, Real-Time Bidding (RTB) стала важной новой парадигмой в медийной рекламе [7]. Например, по данным IAB/PwC, в США в 2024 году объём RTB оценивается в \$82,2 млрд, что составляет 61% от всей вычислительной рекламы или 52,8% от общего объема интернет рекламы [6]. В отличие от прямых продаж рекламных размещений и закупок по заранее согласованным фиксированным ценам, RTB позволяет через аукцион за каждый отдельный показ выбирать наиболее релевантное объявление для конкретного пользователя. Это даёт рекламодателям возможность точнее достигать целевой аудитории и эффективнее расходовать бюджет, а пользователям – чаще видеть объявления, соответствующие их интересам.

Краткая схема взаимодействия основных компонентов экосистемы RTB показана на Рисунке 2.1. Процесс начинается с того, что пользователь по-




Рис. 2.1: Упрощенная иллюстрация взаимодействия между пользователем, рекламной биржей и DSP

сещает сайт/приложение, содержащее рекламный инвентарь: при загрузке страницы клиент отправляет запрос в рекламную биржу (ad exchange), чтобы определить, какое рекламное объявление будет показано в доступном

рекламном слоте и по какой цене (этап 1 на Рис. 2.1).

Далее биржа рассылает запросы на ставки (bid requests) в различные автоматизированные системы покупки рекламы (Demand-Side Platforms, DSP) (этап 2 на Рис. 2.1). Запрос ставки обычно содержит сведения об издателе и контексте размещения (например, URL/домен, тематика, характеристики рекламного слота), а также признаки пользователя (чаще всего идентификаторы на основе cookie/устройств) и технические параметры (тип устройства, ОС, браузер и т.п.).

Получив запрос, DSP решает две ключевые задачи:

- (1) Следует ли участвовать в аукционе и от имени какого рекламодателя/кампании (в зависимости от таргетинга, ограничений бюджета и частотных ограничений);
- (2) Если участвовать, то вычислить величину ставки.

После этого DSP отправляет свой ответ (bid response) обратно на биржу (этап 3 на Рис. 2.1).

Рекламная биржа проводит аукцион после получения ответов от всех DSP либо по истечении лимита по времени (этап 4 на Рис. 2.1). На практике часто используется аукцион Викри, также известный как аукцион второй цены: участник с наибольшей ставкой выигрывает показ, но платит цену, близкую ко второй по величине ставке. После определения победителя биржа уведомляет выигравшую DSP о факте победы и цене (win notice) (этап 5 на Рис. 2.1).

Далее биржа возвращает на страницу параметры показа/ссылки на креатив (этап 6 на Рис. 2.1); клиент загружает креатив с рекламного сервера, и пользователь видит объявление на площадке издателя. Если объявление заинтересовало пользователя, он может кликнуть по нему и перейти на страницу рекламодателя, а затем совершить целевое действие (conversion).

Эти события (показ, клик, конверсия) формируют пользовательскую обратную связь, которая через механизмы трекинга передаётся участникам цепочки и используется для оптимизации закупки (этап 7 на Рис. 2.1).

Хорошо известно, что длительная загрузка страницы значительно снижает удовлетворённость пользователей [9], поэтому DSP обычно обязаны возвращать ставку в очень короткие сроки (например, 100 мс). Более подробные сведения об RTB можно найти в статьях [7, 8].

Цель оптимизации алгоритма назначения ставок на стороне DSP – улучшение ключевых показателей эффективности (Key Performance Indicator – KPI) рекламодателей, таких как число кликов и/или число конверсий при фиксированном бюджете кампании. Поэтому алгоритм назначения ставок является ключевым компонентом успешной DSP: именно здесь вычислительная реклама напрямую опирается на анализ больших данных (Big Data) и аналитическую инфраструктуру (сбор событий, мониторинг качества трафика, контроль бюджетов и ограничений). Проектирование алгоритма ставок затрагивает множество областей компьютерных наук, включая машинное обучение, анализ данных, статистику, оптимизацию и теорию игр.

Несмотря на популярность, исследователям из академической среды почти невозможно получить доступ к чувствительным и потому строго защищённым данным. К счастью, в 2013 году iPinYou провела международное соревнование по алгоритмам RTB, состоявшее из трёх сезонов, основная задача которого была – решение проблемы оптимизации ставок DSP (DSP Bid Optimisation Problem). В марте 2014 года набор данных, использованный в трёх сезонах соревнования, был опубликован для исследовательских целей [5]. Насколько известно, это первый крупный набор данных RTB в публичном доступе.

Для работы с данным объёмом и структурой логов целесообразно использовать систему управления базами данных (СУБД): это упрощает по-

вторяемые аналитические запросы, обеспечивает воспроизводимость расчётов, централизует хранение и контроль качества данных, а также позволяет эффективно агрегировать события на больших выборках. В рамках работы используется ClickHouse – колоночная СУБД, ориентированная на высокопроизводительную аналитическую обработку. ClickHouse хорошо подходит для задач статистического анализа логов RTB благодаря эффективному сжатию колонок, быстрому выполнению агрегирующих запросов по большим таблицам, поддержке материализованных представлений/вычисляемых столбцов и возможности масштабирования под рост объёма данных. Например, по сравнению с другой популярной СУБД PostgreSQL – ClickHouse в типовых аналитических запросах может обеспечивать более чем 20-кратное ускорение выполнения [4].

Для интерактивной визуализации результатов анализа и подготовки воспроизводимых отчётов в работе используется Yandex DataLens – BI-инструмент для построения дашбордов и исследовательской аналитики. DataLens позволяет подключаться к ClickHouse как к источнику данных, создавать графики и таблицы поверх SQL-запросов, применять фильтры и сегментацию (например, по кампаниям, доменам, типам устройств и времени), а также публиковать единый набор визуализаций для последующей проверки и интерпретации результатов, обновляемый в реальном времени. Использование BI-слоя снижает необходимость ручной генерации графиков в коде, ускоряет итерации анализа и упрощает сравнение метрик в различных разрезах.

В этой работе мы сначала проведём описательный обзор набора данных и его основных сущностей, затем выполним подготовку данных: предобработку с использованием Python, валидацию структуры и типов для последующей загрузки в ClickHouse, а также материализацию отдельных вычисляемых признаков/столбцов в базе данных для оптимизации типовых запросов. Далее будет выполнен детальный статистический анализ

RTB-аукционов и рассчитаны ключевые метрики эффективности рекламных кампаний: Cost Per Mille (CPM), Click-Through Rate (CTR), Conversion Rate (CVR), Effective Cost Per Click (eCPC), Effective Cost Per Action (eCPA). Отдельное внимание будет уделено влиянию факторов контекста и пользователя на указанные метрики, включая тип устройства (desktop/mobile), время (час/день недели/сезонность), параметры площадки (тематика/домен), характеристики рекламного слота, а также доступные признаки пользовательского сегмента (например, cookie/идентификаторы и производные от них агрегаты). Наконец, будет построена RTB-воронка (ставки → показы → клики → конверсии) и подготовлены визуализации с использованием DataLens.

2.1 Цель

Цель работы заключается в выявлении наиболее значимых показателей эффективности путем анализа и визуализации результатов RTB-аукционов на примере открытого набора данных iPinYou с помощью DataLens для решения бизнес задач.

2.2 Объект исследования

Объектом исследования являются данные RTB-аукционов iPinYou, опубликованные для исследовательских целей по итогам соревнования iPinYou RTB Bidding Algorithm Competition.

2.3 Предмет исследования

Предметом исследования являются закономерности и статистические зависимости в данных RTB-аукционов, определяющие результаты рекламного показа и эффективность кампаний: влияние параметров рекламно-

го слота и площадки, времени, устройства и доступных пользовательских признаков на вероятность клика/конверсии, а также на стоимость закупки инвентаря в рамках ограничений бюджета.

2.4 Методы исследования

- Предобработка и анализ данных с использованием Python (очистка, валидация, преобразование признаков).
- Хранение и аналитическая обработка данных в колоночной СУБД ClickHouse (SQL-запросы, агрегирование таблиц, материализация вычисляемых столбцов).
- Построение воронки событий и расчёт рекламных метрик (CPM, CTR, CVR, eCPC, eCPA) в различных срезах и сегментах с использованием Yandex DataLens.
- Анализ и визуализация чартов с использованием Yandex DataLens. Построение интерактивного дашборда.
- Обзор академических и прикладных источников по RTB и оптимизации ставок [8, 11].

2.5 Задачи

Задачи проекта разделяются на две части: исследовательскую и программную.

- **Исследовательская часть**

- Провести описательный обзор набора данных iPinYou и основных сущностей логов (bidding log / impression log / click log / conversion log).

- Выполнить расчёт и интерпретацию ключевых показателей рекламных кампаний: CPM, CTR, CVR, eCPC, eCPA.
- Построить RTB-воронку и оценить потери на каждом этапе.
- Проанализировать влияние факторов контекста и пользователя на метрики эффективности (тип устройства, время, параметры площадки и слота, доступные признаки пользовательского сегмента).
- Пройти курс «DataLens: анализ и визуализация данных» для освоения инструментария построения дашбордов.

• Программная часть

- Подготовить пайплайн предобработки данных в Python: очистка, нормализация форматов.
- Развернуть в облаке базу данных и загрузить подготовленные таблицы.
- Реализовать оптимизации для повторяющегося анализа (агрегации, вычисляемые столбцы/материализованные представления).
- Провести расчет метрик и подготовить визуализации в различных разрезах.
- Построить дашборды в Yandex DataLens для интерактивного анализа метрик и сравнения сегментов.

2.6 Актуальность работы

Актуальность работы обусловлена тем, что RTB является доминирующим механизмом закупки медийной рекламы и формирует значительную часть рынка интернет-рекламы. Набор данных iPinYou предоставляет редкую возможность исследовать реальные логи аукционов и проверить

статистические гипотезы о факторах эффективности кампаний. Дополнительно, использование связки ClickHouse + DataLens позволяет выстроить воспроизводимый контур хранения, расчёта и визуализации метрик, применимый к анализу рекламных логов большого объёма в практических бизнес задачах. Таким образом, можно считать, что актуальность работы продемонстрирована.


2.7 План работы

План выполнения работ и сроки по этапам приведены в Таблице 2.1. Графическое представление плана (диаграмма Ганта) показано на Рис. 2.2.

Таблица 2.1: Календарный план выполнения работы

N	Задача	Дата начала	Дата окончания
1	Обзор литературы по RTB	02.11.2025	30.11.2025
2	Освоение Yandex DataLens	02.11.2025	11.01.2026
3	Обзор датасета iPinYou	15.11.2025	29.11.2025
4	Предобработка данных	04.12.2025	21.12.2025
5	Развёртывание БД и загрузка таблиц	10.12.2025	11.01.2026
6	Оптимизация аналитических запросов	05.01.2026	16.01.2026
7	Расчёт ключевых метрик эффективности	16.01.2026	31.01.2026
8	Построение RTB-воронки и потерь	20.01.2026	28.02.2026
9	Факторный анализ эффективности	01.02.2026	14.03.2026
10	Визуализации и анализ метрик по срезам	14.03.2026	10.04.2026
11	Построение дашбордов в DataLens	01.02.2026	20.04.2026
12	Сопоставление с литературой и выводы	20.04.2026	25.04.2026

Рис. 2.2: Диаграмма Ганта плана выполнения работы



3 Описательный анализ данных

Опубликованный набор данных iPinYou включает несколько типов логов, отражающих ключевые этапы RTB-процесса: журналы ставок в аукционах (bidding log), журналы показов/кликов/конверсий (impression / click / conversion log), а также вспомогательные таблицы (категории рекламодателей, профили пользователей, соответствия регионов и городов). Ниже приведено описание основных сущностей и полей.

3.1 Журнал ставок

Каждая строка журнала содержит сведения из трёх измерений: (1) пользователь, (2) рекламный слот, (3) параметры ставки и рекламной кампании. Формат данных представлен в Таблице 3.1.

Дадим некоторым полям более подробное описание:

- **Timestamp** – момент времени, когда запрос ставки (bid request) поступает на DSP в формате ууууMMddHHmmssSSS.
- **iPinYou ID** – идентификатор пользователя (cookie), установленный iPinYou.
- **User Agent** – информация об операционной системе клиента, типе браузера, модели устройства.
- **IP address** – первые три байта IP-адреса пользователя. Последний байт удаляется в целях защиты приватности.
- **Ad exchange** – идентификатор рекламной биржи, с которой пришёл данный аукцион. Возможные значения: 1–6, соответствующие Tanx (Alibaba), Adx (Google DoubleClick AdX), Tencent (Tencent), Baidu (Baidu), Youku (Youku), Amx (Google Mobile) соответственно.

- **URL, Anonymous URL ID** – URL страницы, на которой должен быть показан рекламный слот. Издатель может запретить передавать этот URL в DSP, в таком случае используется поле **Anonymous URL ID**.
- **Ad slot ID** – уникальный идентификатор рекламного слота (места размещения) на странице. Одна страница может содержать несколько рекламных слотов.
- **Ad slot width, Ad slot height** – ширина и высота рекламного слота. Поля могут быть массивами, что означает допустимость нескольких размеров креатива для данного слота.
- **Ad slot visibility** – видимость слота: на верхней части страницы (FirstView), или ниже (SecondView-TenthView), неизвестно (Na).
- **Ad slot format** – формат слота: фиксированное место (Fixed), всплывающее окно (Pop), неизвестно (Na).
- **Ad slot floor price** – минимальная цена, при которой издатель допускает победу DSP в аукционе. Если ни одна ставка не превышает минимальную, победителя нет. Перед публикацией применяется линейное масштабирование значения. Единица измерения: юань за CPM.
- **Creative ID** – идентификатор рекламного креатива рекламодателя, по которому DSP делает ставку.
- **Bidding price** – ставка DSP в аукционе. Перед публикацией применяется линейное масштабирование значения. Единица измерения: юань за CPM.

- **User Profile IDs** – тэги пользователя, однако в bidding log эти значения всегда пусты по соображениям безопасности. Поле представляет собой массив числовых идентификаторов категорий.

Таблица 3.1: Формат данных bidding log. Столбцы, отмеченные символом *, содержат значения, которые были захэшированы или модифицированы перед публикацией лога.

N	*	Column	Example
1	*	Bid ID	c0550000008e5a94ac18823d6f275121
2		Timestamp	20130218134701883
3	*	iPinYou ID	35605620124122340227135
4		User-Agent	Mozilla/5.0 (Windows NT 5.1) AppleWebKit/535.11 (KHTML, like Gecko) Chrome/17.0.963.84 Safari/535.11 SE 2.X MetaSr 1.0
5	*	IP	119.163.222.*
6		Region ID	146
7		City ID	147
8		Ad Exchange	2
9	*	Domain	e80f4ec7f5bfbc9ca416a8c01cd1a049
10	*	URL	hz55b000008e5a94ac18823d6f275121
11		Anonymous URL	null
12		Ad Slot ID	9737269023493
13		Ad Slot Width	300
14		Ad Slot Height	250
15		Ad Slot Visibility	FirstView
16		Ad Slot Format	Na
17	*	Ad Slot Floor Price	0
18		Creative ID	f80f4ec7f5bfbc9ca416a8c01cd1a049
19	*	Bidding Price	573
20		Advertiser ID	2259
21	*	User Profile IDs	null

3.2 Журнал показов / кликов / конверсий

В журналах показов, кликов и конверсий поля совпадают с журналом ставок. Помимо полей из журнала ставок дополнительно присутствуют следующие поля:

- **Log type** – тип события: 1 (показ), 2 (клик), 3 (конверсия).

- **Paying price** – фактическая цена, которую платит победившая DSP на бирже. Перед публикацией, аналогично ставкам, применяется линейное масштабирование. Единица измерения: юань за CPM.
- **Landing page URL** – URL страницы, на которую переходит пользователь при клике по креативу.

Формат которых описан в Таблице 3.2:

Таблица 3.2: Формат данных impression/click/conversion log. Столбцы, отмеченные символом *, содержат значения, которые были захэшированы или модифицированы перед публикацией лога.

N	*	Column	Example
1		Bid ID	01530000008a77e7ac18823f5a4f5121
2		Timestamp	20130218134701883
3		Log Type	1
4	*	iPinYou ID	35605620124122340227135
5		User-Agent	Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1; WOW64; Trident/5.0)
6	*	IP	118.81.189.
7	*	Region ID	15
8		City ID	16
9		Ad Exchange	2
10	*	Domain	e80f4ec7f5bfb9ca416a8c01cd1a049
11	*	URL	hz55b000008e5a94ac18823d6f275121
12		Anonymous URL	null
13		Ad Slot ID	21476898764813
14		Ad Slot Width	300
15		Ad Slot Height	250
16		Ad Slot Visibility	SecondView
17		Ad Slot Format	Fixed
18	*	Ad Slot Floor Price	0
19		Creative ID	e39e178fdf366606f8cab791ee56bcd
20	*	Bidding Price	753
21	*	Paying Price	15
22	*	Landing Page URL	a8be178fdf366606f8cab791ee56bcd
23		Advertiser ID	3358
24	*	User Profile IDs	123,5678,3456

3.3 Категории рекламодателей

Для идентификации рекламодателя используется поле **Advertiser ID**. Полный перечень категорий рекламодателей приведён в Таблице 3.3.

Таблица 3.3: Категории рекламодателей.

Advertiser Key	Industrial Category
1458	Chinese vertical e-commerce
3358	Software
3386	International e-commerce
3427	Oil
3476	Tire
2259	Milk powder
2261	Telecom
2821	Footwear
2997	Mobile e-commerce app install

3.4 Профиль пользователя

iPinYou разработала классификацию аудитории для описания характеристик пользователей по нескольким аспектам: демография, география, долгосрочные интересы (long-term) и покупательские намерения (in-market).

Данные профилей представляют собой таблицу соответствий между идентификатором категории и её названием.

3.5 Таблица регионов и городов

iPinYou предоставляет два файла: (1) соответствие **region id** → **region name** и (2) соответствие **city id** → **city name**. Все значения регионов и городов относятся к географическим локациям материкового Китая.

3.6 Предварительная обработка данных

Отметим, перед публикацией данных iPinYou исключает из bidding log площадки с подозрительной активностью. Для обнаружения спама используются специализированные алгоритмы фильтрации [5].

В ходе валидации качества данных при помощи скрипта были выявлены и устранены несколько типов аномалий и несоответствий. Во-первых, в таблице bidding log в поле user agent встречались некорректные значения: одиночный символ ”.”, использовавшийся вместо пропуска, а также строки, содержащие IP-адрес. Для таких записей были заданы пустые значения user agent. Во-вторых, было обнаружено, что для части идентификаторов городов, присутствующих в bidding log, отсутствует соответствие в таблице городов (не задано текстовое наименование города) – подобные случаи будут обработаны базой данных во время операций **JOIN**.

Кроме того, в данных встречались записи, где идентификатор рекламной биржи отсутствовал, несмотря на строгий формат возможных значений 1-6. Для обеспечения целостности данных и корректности группировок при последующем анализе было введено дополнительное значение категории – 0, соответствующее случаю Unknown. Наконец, при подготовке файлов к загрузке в СУБД были выявлены различия в кодировке переводов строк (Windows CRLF vs Unix LF): данное несоответствие было устранено на этапе предобработки скриптом для обеспечения корректного парсинга строк.

Для повышения ценности данных на основе поля user agent с помощью отдельной программы-парсера были сформированы два дополнительных признака: browser (тип браузера) и platform (устройство/платформа). Полученные признаки далее используются при сегментации трафика и анализе зависимостей метрик эффективности от технических характеристик пользователя.

4 Обзор источников

Рассматриваемый в работе набор данных iPinYou получил широкое распространение в академических исследованиях по вычислительной рекламе и машинному обучению, поскольку представляет собой редкий пример публично доступных логов RTB-аукционов, включающих события на разных этапах рекламной воронки (запрос ставки, факт показа, клик и конверсия). В частности, данные iPinYou активно используются для задач предсказания отклика пользователя (CTR/CVR), оптимизации назначения ставок на стороне DSP, а также для сравнения стратегий закупки рекламного инвентаря в условиях ограниченного бюджета [8, 11].

В обзорной работе [8] авторы рассматривают RTB как отдельное направление исследований в медийной рекламе и систематизируют ключевые задачи, возникающие на стороне DSP. Существенный акцент делается на том, что решение задачи назначения ставки невозможно свести к одной модели: оно включает (1) оценку вероятности отклика пользователя (например, предсказание клика/конверсии), (2) принятие решения о ставке с учётом бюджета и цели кампании, (3) учёт ограничений и особенностей аукционного механизма. Отдельно отмечаются практические сложности, характерные для RTB: сильная разреженность целевых событий (клики и особенно конверсии), необходимость работы в строгих временных ограничениях. Таким образом, [8] задаёт концепт, в котором связаны предсказательные модели машинного обучения (CTR/CVR) и оптимизационные задачи RTB (назначение ставок, распределение бюджета).

Работа [11] посвящена построению протокола сравнения алгоритмов назначения ставок на основе набора данных iPinYou и фактически является одной из отправных точек для последующих исследований. Авторы проводят первичный анализ структуры и свойств датасета, формулируют постановку задачи DSP Bid Optimization Problem и предлагают подход к

офлайн-оценке стратегий на логах аукционов (симуляция закупки при фиксированном бюджете). Далее рассматривается 2 этапа: сначала обучается модель предсказания вероятности клика и/или конверсии (pCTR/pCVR), затем на основе полученной оценки ценности показа применяется стратегия назначения ставки. В экспериментальной части сравниваются базовые стратегии (в частности, константная ставка и случайное назначение ставок) и более содержательные правила, использующие предсказанную вероятность отклика. Показано, что использование моделей pCTR/pCVR и корректно выбранной стратегии ставок позволяет существенно повысить итоговые KPI по сравнению с наивными базовыми подходами.

5 Проектирование и разработка макета интерактивного дашборда

5.1 Концепция и архитектура дашборда

При проектировании архитектуры дашборда учитывались возможные потребности трех основных групп потенциальных пользователей. Это позволило определить, какие именно данные необходимо размещать на дашборде, а также принципы их разделения и группировки. Выделены следующие основные группы пользователей:

- **Менеджеры проектов, руководители, представители рекламных площадок и рекламодатели.** Данной группе пользователей необходим верхнеуровневый срез данных для оценки общей эффективности рекламных кампаний, контроля расходования бюджета и достижения бизнес-целей (KPI). Их основной фокус направлен на финансовые показатели (CPM, eCPA, eCPC) и метрики конверсии (CTR, CVR), что позволяет принимать управленческие решения об оптимизации рекламных стратегий.
- **Дата-инженеры и дата-аналитики.** Этим специалистам требуется глубокое понимание структуры данных, распределений признаков и наличия аномалий. Им необходимы инструменты для разведочного анализа данных, выявления скрытых закономерностей, подготовки признаков для последующего построения моделей машинного обучения.
- **Разработчики проекта.** Для данной группы важен мониторинг технического состояния системы торгов (win ratio, объемы входящего трафика по типам событий) и анализ влияния различных технических факторов (платформа, браузер, формат слота) на итоговые

метрики. Это необходимо для отладки алгоритмов назначения ставок (bidding) и оптимизации высоконагруженных компонентов системы.

Для удовлетворения потребностей всех перечисленных групп дашборд концептуально разделен на три независимые, но логически связанные вкладки, каждая из которых решает свой класс задач.

5.2 Эффективность RTB-рекламы

Целью данной вкладки является предоставление сводной информации о ключевых показателях эффективности рекламных кампаний для оперативного мониторинга бизнес-результатов. Вкладка ориентирована преимущественно на менеджеров и рекламодателей.

В датасете данные метрики реализуются через вычисляемые поля на основе агрегации базовых событий: суммирование стоимости выигранных ставок для расчета затрат, подсчет количества событий показов (`imp`), кликов (`clk`) и конверсий (`conv`).

Для фильтрации и детализации данных предусмотрены следующие селекторы:

- **Диапазон дат** — для анализа динамики показателей за выбранный период.
- **Рекламодатель** — для оценки эффективности кампаний конкретного клиента.
- **Платформа (ОС) и Браузер** — для сегментации аудитории по техническим характеристикам.

На вкладке предполагается размещение следующих визуализаций:

- Индикаторы с текущими значениями ключевых метрик и спарклайнами для отображения краткосрочных трендов.

- Линейный график динамики основных КРІ с течением времени.
- Столбчатая диаграмма распределения бюджета и количества кликов/конверсий по топ-5 рекламодателям.
- Таблица с детализацией метрик по рекламным кампаниям.

На рисунке 5.1 представлен макет вкладки «Эффективность рекламы».




Рис. 5.1: Макет вкладки «Эффективность рекламы»

5.3 Разведочный анализ данных (EDA)

Цель данной вкладки — предоставить аналитикам инструменты для глубокого погружения в структуру собранного датасета, выявления распределений, паттернов и возможных аномалий в трафике.

Для реализации задач EDA необходимы следующие визуализации:

- **RTB-воронка:** Bid → Impression → Click → Conversion. Позволяет визуально оценить потери трафика на каждом этапе взаимодействия пользователя с рекламой.
- **Гистограммы распределения** событий по времени суток и дням недели для выявления сезонности и пиков активности пользователей.
- **Круговые или кольцевые диаграммы** долей трафика по платформам (ОС) и браузерам.
- **Таблица или график распределения** трафика по рекламной бирже (Ad Exchange)/региону/городу.
- **График относительного спреда ставок:** визуализация отношения разности между максимальной и минимальной ценой ставки к их среднему значению в разрезе временных интервалов или сегментов аудитории. Позволяет оценить волатильность аукционных цен и выявить сегменты с нестабильной конкурентной средой.

Данные чарты помогут выявить такие паттерны, как преобладание мобильного трафика в определенные часы, аномально низкий трафик на специфических доменах, непропорционально высокую стоимость клика в отдельных регионах, а также сегменты с высокой волатильностью аукционных цен, диагностируемой через относительный спред ставок.

На рисунке [5.2](#) представлен макет вкладки «EDA».




Рис. 5.2: Макет вкладки «EDA»

5.4 Многофакторный анализ KPI рекламных кампаний

Цель данного раздела дашборда — предоставить гибкий инструмент для исследования влияния различных технических и контекстных факторов на итоговую эффективность рекламы. Это позволяет находить неочевидные инсайты для оптимизации таргетинга, корректировки ставок и улучшения пользовательского опыта.

Главной особенностью данной вкладки является интерактивность: с по-

мощью специального селектора, реализованного через механизм параметров, пользователь дашборда может динамически выбирать целевую метрику для анализа (CTR, CVR, CPM, eCPC или eCPA). Все графики на вкладке автоматически перестраиваются для отображения распределения выбранной метрики в различных срезах.

Для всестороннего анализа на вкладке представлены следующие визуализации:

- **Влияние места размещения:** столбчатая диаграмма, показывающая, как выбранная метрика зависит от расположения рекламного блока на странице.
- **Влияние платформы и браузера:** линейчатая диаграмма, показывающая, как выбранная метрика зависит от платформы/браузера.
- **Влияние типа рекламы:** столбчатая диаграмма, демонстрирующая разницу в эффективности между всплывающими (popup) и фиксированными форматами рекламы.
- **Влияние времени:** линейный график, отображающий динамику метрики в зависимости от часа дня/дня недели, что критично для настройки временного таргетинга.
- **Влияние размера креатива:** диаграмма рассеяния (Scatter plot) или ящичковая диаграмма (Box plot), позволяющая оценить, какие габариты баннеров (ширина и высота) приносят наилучший результат.

На рисунке [5.3](#) представлен макет вкладки «Многофакторный анализ».

Datalens




Рис. 5.3: Макет вкладки «Многофакторный анализ»

6 Инфраструктура хранения и подготовки данных

Настоящий раздел описывает технический контур, обеспечивающий хранение, нормализацию и аналитическую доступность данных iPinYou: от обоснования выбора СУБД и её развёртывания до определения схемы таблиц, формирования итоговой денормализованной таблицы и подключения к BI-инструменту Yandex DataLens.

6.1 Выбор и развёртывание СУБД

Объём исходных данных и требования к хранилищу

В работе использованы два сезона соревнования iPinYou (сезон 2 и сезон 3), имеющих идентичный формат. Совокупный объём загруженных файлов после предобработки приведён в Таблице 6.1.

Таблица 6.1: Объём обогащённых TSV-файлов по типам логов и сезонам.

Тип лога	Сезон 2 (строк)	Сезон 3 (строк)	Итого (строк)
Bidding log	53 289 330	11 457 419	64 746 749
Impression log	12 237 087	3 158 171	15 395 258
Click log	9 978	2 716	12 694
Conversion log	494	539	1 033

Совокупный объём журнала ставок превышает 75 миллионов записей, а суммарный размер обогащённых TSV-файлов составляет порядка 30 ГБ. Данный масштаб данных определяет требования к хранилищу: необходимы эффективное сжатие, быстрое выполнение агрегирующих запросов по большим выборкам и поддержка вычисляемых столбцов.

Выбор СУБД: сравнение альтернатив

При выборе инструмента хранения и обработки данных рассматривались три варианта.

Загрузка файлов напрямую в Yandex DataLens. DataLens поддерживает загрузку CSV/TXT-файлов в качестве источника данных. Однако данный подход неприменим в рамках настоящей работы по ряду причин: (1) любой запрос к файловому источнику выполняет полное сканирование всех строк без возможности использования индексов или ключей сортировки; (2) доступный набор функций и агрегаций существенно ограничен по сравнению с полноценной СУБД; (3) максимальный допустимый объём загружаемого файла составляет 400 МБ, тогда как совокупный объём данных настоящей работы превышает этот предел более чем в 70 раз.

PostgreSQL. Реляционная СУБД PostgreSQL [13] является широко распространённым решением для хранения структурированных данных. Тем не менее для аналитических нагрузок, характерных для данной работы (агрегирование по десяткам миллионов строк, группировка по множеству измерений), PostgreSQL уступает колоночным СУБД: строковое хранение данных требует чтения всей строки даже при обращении к одному-двум столбцам, а отсутствие нативной векторизации запросов приводит к значительно более высокой латентности.

ClickHouse. Колоночная СУБД ClickHouse [3] оптимизирована для высокопроизводительной аналитической обработки (OLAP) и наилучшим образом соответствует требованиям настоящей работы. Ключевые преимущества ClickHouse применительно к задаче анализа RTB-логов:

- **Колоночное хранение и сжатие.** Данные хранятся по столбцам, что позволяет читать только те столбцы, которые задействованы в запросе, и применять эффективные алгоритмы сжатия к однородным данным каждого столбца.

- **Векторизованное выполнение запросов.** Операции над данными выполняются блоками (batch processing), что позволяет эффективно использовать SIMD-инструкции процессора и существенно ускоряет агрегирование по большим таблицам.
- **Материализованные столбцы.** ClickHouse поддерживает объявление вычисляемых столбцов (MATERIALIZED), значения которых однократно вычисляются по мере работы с таблицей, что обеспечивает эффективное управления ресурсами при работы с большими объемами данных.

Установка и развёртывание

ClickHouse устанавливался локально с использованием официальной документации [12].

После установки сервер запускается командой `clickhouse server`, а клиент – командой `clickhouse client`. Загрузка данных осуществлялась путём прямой передачи предварительно подготовленных TSV-файлов в стандартный поток ввода.

6.2 Схема исходных таблиц

Для каждого типа лога создана отдельная таблица: `bid_log`, `imp_log`, `clk_log`, `conv_log`. Все таблицы используют движок `MergeTree` с сортировкой по вычисляемому столбцу `ts`.

Ключевые решения по типам данных:

- **Timestamp** хранится в исходном виде как `String` в поле `timestamp_raw` (формат `yyyyMMddHHmmssSSS`); разбор в тип `DateTime64(3)` выполняется материализованным столбцом `ts`

- **Advertiser ID** в исходных таблицах объявлен как `Nullable(UInt32)`; в итоговой аналитической таблице (см. подраздел 6.3) переведён в обязательное поле с `DEFAULT 0` для обеспечения корректной сортировки и группировки.
- **Platform / Browser** – два дополнительных столбца, добавленных скриптом обогащения на этапе предобработки поля `user_agent`.

6.3 Формирование аналитической таблицы `ads_data`

Логика объединения таблиц

Итоговая аналитическая таблица `ads_data` формируется путём объединения четырёх исходных таблиц по ключу `bid_id`. Центральной таблицей является `bid_log`, содержащая все зафиксированные ставки DSP. К ней последовательно при помощи `ANY LEFT JOIN` присоединяются:

- `imp_log` – для получения факта победы в аукционе и фактической цены показа (`paying_price`);
- `clk_log` – для получения факта клика по объявлению и URL целевой страницы (`landing_page_url`);
- `conv_log` – для получения факта конверсии.

По результатам объединения в таблицу добавляются три булевых флага:

- `is_win` – ставка выиграла аукцион (присутствует запись в `imp_log`);
- `is_clicked` – показ сопровождался кликом пользователя (присутствует запись в `clk_log`);
- `is_conversion` – клик привёл к конверсии (присутствует запись в `conv_log`).

Итоговая таблица `ads_data`

Поскольку поле `advertiser_id` в промежуточной таблице объявлено как `Nullable(UInt32)`, а большинство аналитических запросов предполагают группировку и фильтрацию по рекламодателю, была выполнена дополнительная трансформация: пустые значения `advertiser_id` заменены на 0 (категория «Unknown»), а тип самого поля переведен в `UInt32`: это нужно чтоб создать новую таблицу с другим ключом сортировки `ORDER BY advertiser_id`. Результирующая таблица получила название `ads_data` и является основным источником данных для всех последующих аналитических запросов и визуализаций.

Преимущества денормализованного подхода

Денормализованная «широкая» таблица `ads_data` предпочтительна для аналитических нагрузок в ClickHouse по ряду причин. Во-первых, ClickHouse оптимизирован для сканирования больших объёмов данных в одной таблице, тогда как выполнение JOIN в реальном времени на десятках миллионов строк существенно увеличивает латентность запросов. Во-вторых, хранение всех атрибутов события в одной строке позволяет DataLens и SQL-запросам обращаться к любому срезу (по времени, рекламодателю, платформе, домену) без дополнительных шагов. В-третьих, однократно вычисленные флаги `is_win`, `is_clicked`, `is_conversion` устраняют необходимость повторного выполнения JOIN при каждом расчёте воронки или метрик эффективности.

6.4 Подключение ClickHouse к DataLens

Yandex DataLens является облачным сервисом и требует сетевой доступности источника данных. Поскольку сервер ClickHouse развёрнут локально, прямое подключение из DataLens к нему невозможно без дополни-

тельных средств проброса сети.

Для решения данной задачи применялся инструмент **ngrok** [14], осуществляющий проброс локального порта через защищённый HTTPS-туннель.

Подключение DataLens к базе данных настроено с использованием TLS-сертификата и парольной аутентификации, что обеспечивает минимальные требования безопасности при работе с публично доступным туннелем. Интерфейс настройки подключения представлен на Рисунке 6.1.

ClickHouse

Подключение: Выбрать в организации Указать вручную Connection Manager

Указать реквизиты БД вручную. Для подключения через публичную сеть.

Имя хоста:

Порт HTTP-интерфейса:

Имя пользователя:

Пароль:

Уровень доступа SQL запросов ?

- ☐ Разрешить подзапросы в датасетах
Опция позволяет описывать источники датасета с помощью SQL-запросов
- ☐ Разрешить подзапросы в датасетах и параметризация источников
Опция позволяет описывать источники датасета с помощью SQL-запросов и использовать параметризацию источников
- ☒ Разрешить подзапросы в датасетах, параметризация источников и QL-чарты !
Опция позволяет описывать источники датасета с помощью SQL-запросов, использовать параметризацию источников и создавать QL-чарты

Настройки кэширования ▼

Продвинутые настройки подключения ^

TLS ? Выкл Вкл

Рис. 6.1: Настройка подключения ClickHouse в интерфейсе Yandex DataLens.

6.5 Формирование датасета

Понятие датасета в DataLens

Датасет в Yandex DataLens представляет собой логическое описание источника данных: он определяет набор таблиц, связи между ними и перечень

полей, доступных для построения чартов. Датасет является промежуточным слоем между физическим хранилищем (ClickHouse) и визуализациями: все вычисляемые поля, созданные на уровне датасета, автоматически становятся доступными во всех чартах, построенных на его основе.

Источники данных и схема связей

Основным источником данных в датасете является таблица `ads_data`. Для декодирования `region_id` и `city_id` в читаемые названия в ClickHouse были созданы две справочные таблицы: `ipinyou_db.cities` и `ipinyou_db.regions`.

Связи между таблицами настраивались непосредственно в интерфейсе датасета DataLens без написания SQL-запросов. К таблице `ads_data` были добавлены два LEFT JOIN:

- `ads_data.city_id = ipinyou_db.cities.city_id` — для получения поля `city_name`;
- `ads_data.region_id = ipinyou_db.regions.region_id` — для получения поля `region_name`.

Схема связей датасета представлена на Рисунке 6.2.




Рис. 6.2: Схема связей датасета в интерфейсе Yandex DataLens: `ads_data` ← LEFT JOIN → `regions`, `cities`.

7 Заключение

В ходе выполнения курсовой работы был проведен комплексный анализ данных RTB-аукционов на основе открытого датасета iPinYou. Был спроектирован и реализован полный цикл обработки данных: от очистки и нормализации сырых логов до развертывания аналитического хранилища на базе колоночной СУБД ClickHouse и построения интерактивного дашборда в Yandex DataLens. Результаты работы позволяют наглядно оценивать эффективность рекламных кампаний и исследовать факторы, влияющие на ключевые метрики (CTR, CVR, CPM).

7.1 Описание выполненных задач

Во время написания работы были решены все поставленные задачи:

- **Проведен описательный обзор набора данных iPinYou и основных сущностей логов.** Результаты обзора, включая структуру таблиц и описание полей, представлены в разделе 3 (Таблицы 3.1, 3.2, 3.3).
- **Выполнен расчёт и интерпретация ключевых показателей рекламных кампаний.** Метрики CPM, CTR, CVR, eCPC, eCPA рассчитаны и визуализированы на первой вкладке дашборда (Рисунки 7.1, 7.2, 7.3).
- **Построена RTB-воронка и оценены потери на каждом этапе.** Воронка реализована в виде Advanced Chart [15] в DataLens и представлена на Рисунке 7.4.
- **Проанализировано влияние факторов контекста и пользователя на метрики эффективности.** Многофакторный анализ реализован на третьей вкладке дашборда (Рисунки 7.7, 7.8, 7.9).

- **Подготовлен пайплайн предобработки данных в Python.** Описание процесса очистки и обогащения данных приведено в подразделе 3.6, полный исходный код представлен в [GitHub репозитории](#).
- **Развернута база данных и реализованы оптимизации.** Обоснование выбора ClickHouse, развертывание СУБД, ключевые архитектурные решения и процесс денормализации описаны в разделе 6. DDL-определения схем доступны в [репозитории GitHub](#). Стоит отметить, что изначальная задача развертывания базы данных в облаке была скорректирована: в связи с отсутствием гранта на Yandex Cloud, ClickHouse был развернут локально. Тем не менее, суть задачи по созданию аналитического хранилища, доступности данных и оптимизации запросов была полностью выполнена.
- **Построен дашборд в Yandex DataLens.** Процесс проектирования описан в разделе 5, а итоговые визуализации представлены в подразделе 7.2. Сам дашборд доступен по [ссылке](#).
- **Пройден курс по Yandex DataLens.** В рамках освоения инструмента визуализации был успешно пройден курс, сертификат о прохождении которого представлен в [Приложении](#).

7.2 Описание интерактивной визуализации

Разработанный дашборд состоит из трех логических вкладок, решающих различные аналитические задачи. Для удобства анализа на всех вкладках предусмотрена единая панель фильтров, включающая стандартные селекторы: платформа (ОС), браузер, рекламодатель и диапазон дат. Селектор дат, в частности, позволяет фильтровать данные по сезонам соревнования (сезон 2 и сезон 3).

На Рисунках 7.1, 7.2 и 7.3 представлена первая вкладка «Эффективность рекламы». На Рисунке 7.1 отображены ключевые показатели (KPI) в виде индикаторов со спарклайнами, показывающими динамику CTR, CVR, CPM, а также общие затраты бюджета, eCPC и eCPA. Рисунок 7.2 демонстрирует тренды вовлеченности и конверсии с наложенным скользящим средним, а также распределение бюджета и кликов по топ-рекламодателям. Из графиков видно, что рекламодатель «International e-commerce» расходует наибольший бюджет, однако по объему кликов лидирует «Chinese vertical e-commerce». Рисунок 7.3 содержит сводную таблицу со статистикой по всем рекламодателям, позволяющую детально сравнить их эффективность.




Рис. 7.1: Вкладка 1: Ключевые показатели эффективности (KPI)




Рис. 7.2: Вкладка 1: Тренды вовлеченности и распределение бюджетов

Сводная статистика по рекламодателям

Базовая статистика, Таблица

Рекламодатель	Общее число ставок	Число показов	Число кликов	Число конверсий	Суммарные затраты	Доля выигранных аукционов	CTR	CVR	CPM	eCPC	eCPA
Chinese vertical e-commerce	14 701 496	3 077 016	2 450	1	211 938 121	20,93%	0,080%	0,041%	68,88	86 505,36	211 938 121,00
Footwear	5 292 053	1 305 287	823	437	116 696 494	24,67%	0,063%	53,098%	89,40	141 794,04	267 040,03
International e-commerce	14 091 931	2 835 897	2 079	0	217 718 557	20,12%	0,073%	0,000%	76,77	104 722,73	null
Milk powder	2 987 731	830 685	279	89	77 273 250	27,80%	0,034%	31,900%	93,02	276 965,05	868 238,76
Mobile e-commerce app install	1 017 927	311 373	1 382	0	19 625 531	30,59%	0,444%	0,000%	63,03	14 200,82	null
Oil	14 032 619	2 581 615	1 917	0	208 912 977	18,40%	0,074%	0,000%	80,92	108 979,12	null
Software	3 751 016	1 727 542	1 367	377	159 313 651	46,06%	0,079%	27,579%	92,22	116 542,54	422 582,63
Telecom	2 159 708	684 966	207	0	61 372 941	31,72%	0,030%	0,000%	89,60	296 487,64	null
Tire	6 712 268	1 968 277	1 025	26	155 933 746	29,32%	0,052%	2,537%	79,22	152 130,48	5 997 451,77
Itoro	64 746 749	15 322 658	11 529	930	1 228 785 268	23,67%	0,075%	8,067%	80,19	106 582,12	1 321 274,48

Построено в DataLens

Рис. 7.3: Вкладка 1: Сводная статистика по рекламодателям

Вторая вкладка «EDA» (Рисунки 7.4, 7.5, 7.6) посвящена разведочному анализу. На Рисунке 7.4 визуализирована RTB-воронка, наглядно демонстрирующая колоссальные потери трафика на каждом этапе: из 53 млн ставок лишь 22,9% выигрывают аукцион, из показов только 0,072% конвертируются в клики, а из кликов — 4,57% в целевые действия. Рисунок 7.5 показывает структуру трафика: преобладание ОС Windows и браузера IE/Chrome, а также распределение по регионам Китая (лидирует Guangdong), для которого предусмотрен селектор TOP-K, позволяющий гибко настраивать количество отображаемых регионов. Рисунок 7.6 иллюстрирует временную динамику объема трафика в разрезе часа дня, показывая спад активности в ночные часы и пик в вечернее время. Также на этом рисунке представлена гистограмма распределения относительного спреда, характеризующая конкурентность аукциона.




Рис. 7.4: Вкладка 2: RTB-воронка



Рис. 7.5: Вкладка 2: Структура трафика по платформам, браузерам и регионам




Рис. 7.6: Вкладка 2: Объем трафика по часам и распределение спреда

Третья вкладка «Многофакторный анализ» (Рисунки 7.7, 7.8, 7.9) позволяет исследовать влияние различных параметров на выбранную метрику (в данном примере — CTR). Уникальность данной вкладки заключается в ее интерактивности: благодаря селектору выбора анализируемой метрики, пользователь может проверять огромное количество гипотез, используя всего 7 динамически перестраиваемых графиков в зависимости от выбранной метрики (столбчатые диаграммы для формата, места размещения, платформы и браузера, диаграмму рассеяния для размера креатива, а также линейные графики для временной динамики по дням недели и часам). Рисунок 7.7 показывает, что всплывающий формат рекламы (Pop) имеет значительно более высокий CTR по сравнению с фиксированным (Fixed), а диаграмма рассеяния демонстрирует линейную зависимость метрики от размера креатива. На Рисунке 7.8 видно влияние контекста: размещение FirstView показывает наилучший результат, а мобильные платформы (Android, iPhone) демонстрируют более высокий CTR по сравнению с десктопными. Рисунок 7.9 отражает временную динамику метрики, показывая зависимость от дня недели и часа.




Рис. 7.7: Вкладка 3: Влияние формата и размера креатива на метрику




Рис. 7.8: Вкладка 3: Влияние места размещения, платформы и браузера




Рис. 7.9: Вкладка 3: Временная динамика метрики

7.3 Ответ на основной вопрос работы

Основным вопросом исследования являлось определение масштаба потерь на каждом этапе RTB-воронки и выявление факторов, оказывающих наиболее сильное влияние на эффективность рекламных кампаний.

Анализ воронки показал катастрофические потери на каждом этапе: из всех сделанных ставок выигрывают лишь около 22%, из показов в клики переходит всего 0,072%, а из кликов в конверсии — около 4,5-5%. В итоге до целевого действия доходит порядка 0,001% от начального числа ставок. Это подчеркивает сложность задачи оптимизации ставок: алгоритмам DSP приходится обрабатывать десятки миллионов строк логов ради получения

сотен конверсий, что делает критически важным правильный выбор аналитической инфраструктуры (в данном случае — ClickHouse).

При анализе факторов выявлены следующие ключевые закономерности:

- **Формат и размер креатива:** Всплывающие окна (PopUp) показывают CTR, превышающий фиксированные форматы более чем в 10 раз, при разнице в CPM всего в 2 раза. Размер креатива также линейно влияет на CTR, но пропорционально увеличивает стоимость показа.
- **Видимость и устройство:** Размещение в первой зоне видимости (FirstView) увеличивает CTR в 2,7 раза по сравнению со следующей зоной при сопоставимом CPM. Мобильные устройства демонстрируют значительно больший CTR при примерно одинаковой цене покупки по сравнению с десктопами.
- **Время:** Час дня оказывает существенное влияние на вовлеченность, в то время как день недели оказался достаточно слабым признаком.
- **Конверсия (CVR):** Интересным инсайтом стало то, что фиксированный формат рекламы имеет CVR в 2 раза выше, чем PopUp. Это свидетельствует о том, что высокий CTR всплывающих окон во многом обусловлен случайными нажатиями, а не реальным интересом. Также CVR выше у десктопных устройств. Это можно объяснить тем, что пользователи чаще совершают сложные целевые действия (например, покупки, заполнение форм регистрации) с персональных компьютеров благодаря большому экрану, в то время как мобильные устройства чаще используются для потребления контента.

Важно отметить, что не существует единого определения «эффективной рекламы». Рекламодатель должен самостоятельно определять приори-

теты (максимизация охвата, кликов или конверсий) и стратегию расхода бюджета. Разработанный дашборд на базе Yandex DataLens предоставляет необходимую гибкость для принятия таких аналитических решений.

7.4 Ограничения работы

В ходе выполнения работы был выявлен ряд ограничений:

- **Сложность визуализации специфичных данных:** Реализация нестандартных графиков, таких как RTB-воронка, потребовала использования функционала Advanced Charts в DataLens, что сопряжено с необходимостью написания фронтенд-кода на JavaScript и глубокого погружения в документацию сервиса.
- **Актуальность данных:** Набор данных iPinYou, несмотря на свою полноту и академическую ценность, является относительно старым. Экосистема RTB активно развивается, появляются новые форматы и алгоритмы, поэтому для подтверждения выявленных закономерностей в современных реалиях требуется анализ более свежих датасетов при сохранении аналогичного уровня детализации.

7.5 Развитие работы

Дальнейшее развитие проекта может осуществляться в следующих направлениях:

- **Расширение визуализаций:** Добавление тепловых карт (Heatmaps) для более глубокого анализа поведения различных категорий пользователей и выявления неочевидных сегментов аудитории.
- **Машинное обучение:** Использование подготовленного датасета для обучения моделей машинного обучения с целью предсказания вероят-

ности клика (pCTR) и конверсии (pCVR), что является ядром алгоритмов назначения ставок в реальных DSP. Как показал обзор литературы, именно применение машинного обучения является стандартом индустрии для оптимизации стратегии назначения ставок.

- **Мониторинг в реальном времени:** Адаптация инфраструктуры для потоковой загрузки логов и мониторинга RTB-метрик в режиме реального времени. Добавление функционала сравнения текущих показателей с результатами предыдущих периодов (неделя/месяц) для отслеживания долгосрочных трендов и повышения контроля за назначением ставок.

8 Описание применения генеративной модели

В рамках настоящей работы генеративные модели применялись в качестве вспомогательного инструмента на этапе проектирования пользовательского интерфейса дашборда. Основная цель их использования состояла в ускорении процесса создания и доработки макетов визуализаций, избавляя от необходимости ручного редактирования в графических редакторах.

Для задач редактирования существующих макетов и генерации новых прототипов на основе черновых рукописных эскизов использовалась мультимодальная генеративная модель **Nano Banana 2**, поддерживающая работу с изображениями в режиме диалога.

В процессе проектирования сформированные макеты вкладок дашборда загружались непосредственно в чат с моделью. Далее в текстовом сообщении формулировались конкретные правки, которые требовалось внести. Например:

- Устранение визуальных аномалий от предыдущих итераций
- Изменение цветовой схемы
- Изменение типов и содержания графиков

Помимо редактирования готовых прототипов, модель Nano Banana 2 применялась для преобразования рукописных эскизов в оформленные макеты. Процесс состоял из следующих шагов: предварительно был нарисован от руки эскиз, отражающий желаемую компоновку элементов вкладки дашборда (расположение блоков, типы графиков, структура фильтров). Полученный эскиз был сфотографирован и загружен в диалог с моделью, после чего сформулирован промт: оформить эскиз в виде макета дашборда с соблюдением стандартов визуального представления данных.

Для подготовки макета одной из вкладок дашборда также использовалась генеративная модель **Recraft V4**, специализирующаяся на создании изображений по текстовому описанию.

В отличие от подхода с Nano Banana 2, где взаимодействие строилось на основе загружаемых изображений и итеративных правок, работа с Recraft V4 предполагала составление единого детального текстового промта. Промт содержал максимально подробное описание требуемого макета: перечень вкладок и их назначение, типы визуализаций для каждого блока (линейные графики, столбчатые диаграммы, индикаторы KPI, таблицы), расположение элементов на странице, цветовую схему, наличие и состав панели фильтров, а также стилистические требования к оформлению (деловой стиль, тёмная или светлая тема, типографика).

Оба инструмента дополняют друг друга: Nano Banana 2 обеспечивает гибкость редактирования на основе существующих изображений, тогда как Recraft V4 позволяет получить качественный первичный прототип по детальному текстовому описанию. Совместное применение этих моделей охватывает полный цикл дизайн-процесса — от первичного прототипирования до финальной доработки макетов вкладок дашборда.

Список литературы

1. iPinYou company introduction. — Текст : электронный // iPinYou : [сайт]. — URL: https://www.ipinyou.com/aboutus/company_introduction (дата обращения: 20.11.2025).
2. Что такое Yandex DataLens. — Текст : электронный // Yandex DataLens : [сайт]. — URL: <https://datalens.ru/> (дата обращения: 02.11.2025).
3. Что такое ClickHouse. — Текст : электронный // ClickHouse : [сайт]. — URL: <https://clickhouse.com/> (дата обращения: 10.12.2025).
4. Сравнение ClickHouse с PostgreSQL. — Текст : электронный // ClickHouse : [сайт]. — URL: <https://clickhouse.com/docs/ru/migrations/postgresql/overview> (дата обращения: 10.12.2025).
5. iPinYou Global RTB Bidding Algorithm Competition Dataset. — Текст : электронный // iPinYou Contest : [сайт]. — URL: <https://contest.ipinyou.com/ipinyou-dataset.pdf> (дата обращения: 15.11.2025).
6. Internet Advertising Revenue Report Full-year 2024 results. — Текст : электронный // IAB : [сайт]. — URL: https://www.iab.com/wp-content/uploads/2025/04/IAB_PwC-Internet-Ad-Revenue-Report-Full-Year-2024.pdf (дата обращения: 20.11.2025).
7. The Arrival of Real Time Bidding (2011) / Google. — Текст : электронный // RTBchina : [сайт]. — URL: <https://www.rtbchina.com/wp-content/uploads/2012/03/Google-White-Paper-The-Arrival-of-Real-Time-Bidding-July-2011.pdf> (дата обращения: 12.11.2025).

8. Jun Wang and Shuai Yuan. // Real-Time Bidding: A New Frontier of Computational Advertising Research. — Текст : электронный // DL ACM : [сайт]. — URL: <https://dl.acm.org/doi/10.1145/2684822.2697041> (дата обращения: 17.11.2025).
9. The Need for Mobile Speed (2018) / Google. — Текст : электронный // Think With Google : [сайт]. — URL: <https://www.thinkwithgoogle.com/marketing-strategies/app-and-mobile/mobile-page-speed-new-industry-benchmarks/> (дата обращения: 15.12.2025).
10. What is a demand-side platform. — Текст : электронный // Amazon Ads : [сайт]. — URL: <https://advertising.amazon.com/library/guides/demand-side-platform#1> (дата обращения: 16.11.2025).
11. Weinan Zhang, Shuai Yuan, Jun Wang, Xuehua Shen. // Real-Time Bidding Benchmarking with iPinYou Dataset. — Текст : электронный // Arxiv : [сайт]. — URL: <https://arxiv.org/abs/1407.7073> (дата обращения: 25.11.2025).
12. Quick Install — ClickHouse. — Текст : электронный // ClickHouse : [сайт]. — URL: <https://clickhouse.com/docs/install/quick-install> (дата обращения: 10.12.2025).
13. PostgreSQL: The World's Most Advanced Open Source Relational Database. — Текст : электронный // PostgreSQL : [сайт]. — URL: <https://www.postgresql.org/> (дата обращения: 10.12.2025).
14. ngrok — Unified Application Delivery Platform for Developers. — Текст : электронный // ngrok : [сайт]. — URL: <https://ngrok.com/> (дата обращения: 10.12.2025).

15. Создание чарта на основе редактора — Yandex Cloud. — Текст : электронный // Yandex Cloud : [сайт]. — URL: <https://yandex.cloud/ru/docs/datalens/charts/editor/> (дата обращения: 15.02.2026).

Приложение

Приложение 1: Свидетельство о прохождении курса «DataLens: анализ и визуализация данных»

Yandex Cloud
Training & Certification



Дмитрий Наседкин

Свидетельство подтверждает прохождение
курса «DataLens: анализ и визуализация
данных»

18 января 2026 г.



Геннадий Поросенков
Руководитель Yandex Cloud
Training & Certification

Handwritten signature of Genadiy Porosenkov.